

Répartition des tâches — Atlantic Haven Hotels

Hackathon Machine Learning & Data Science — ISPM Madagascar

Équipe de 7 membres · 08h00 – 16h00 · Version finale

Rôles de l'équipe

1. Data Engineer & Chef de Projet

[Nom]

- Setup du dépôt GitHub (structure de dossiers, accès équipe) et chargement/nettoyage des données à partir du data_dictionary.csv.
- Responsable de l'intégration : fusionne les contributions de chacun dans notebook.ipynb aux points de synchro, gère les conflits Git.
- Vérifie la checklist finale avant le dernier commit (16h00).

2. Data Analyst — EDA

[Nom]

- Analyse la cible, les distributions, les valeurs atypiques et les relations temporelles train/test.
- Identifie les scénarios fréquents d'annulation (question Q5).
- Produit les graphiques clés, transmis au Membre 7 pour la vidéo.

3. ML Engineer — Baseline & Validation Temporelle

[Nom]

- Construit le pipeline de prétraitement (fit uniquement sur train, gestion des catégories jamais vues — question Q6).
- Entraîne la régression logistique baseline et calcule le premier F1-score de référence.
- Définit et documente précisément le protocole de validation temporelle (dates/proportions retenues) utilisé ensuite par tous les modèles (question Q4).

4. Feature Engineer

[Nom]

- Crée les nouvelles variables (dates, séjour, prix, historique).
- Vérifie explicitement l'absence de fuite de cible sur chaque variable créée.
- Quantifie le gain de F1-score de chaque groupe de variables (question Q3).

5. Lead Data Scientist — Optimisation

[Nom]

- Entraîne au moins deux familles de modèles alternatifs (Random Forest, XGBoost/LightGBM).
- Règle les hyperparamètres et choisit le seuil de décision, avec le Membre 6 pour la justification métier.
- Génère le fichier submission.csv au format sample_submission.csv.

6. Analyste Métier & Rédacteur Technique

[Nom]

- Rédige le README.md en continu tout au long de la journée (ne pas attendre 15h15).
- Répond aux questions métier Q1, Q2, Q4 (avec le Membre 3), Q6, Q7 et Q8.
- Co-pilote l'analyse d'erreurs (question Q9) avec le Membre 7.

7. Communicant / Réalisateur Vidéo & Analyse d'erreurs

[Nom]

- Démarre l'analyse des faux positifs / faux négatifs dès 13h00, sur un modèle même provisoire — ne pas attendre le modèle final.
- Écrit le script de la vidéo et rassemble les graphiques du Membre 2.
- Enregistre la vidéo (3 à 5 minutes) dès que le modèle final est figé, vers 14h30.

Chronogramme synchronisé

Créneau	Objectif collectif	Qui fait quoi
08h00–09h00	Cadrage & prise en main	Tous : lecture du dictionnaire de données, répartition des accès
09h00–10h30	EDA + Protocole de validation	M2 : EDA complète · M3 : définit le split temporel
10h30–11h30	Baseline	M1, M3 : pipeline + régression logistique + 1er F1-score de référence
11h30–13h00	Feature engineering	M4 (support M1) : variables + vérification anti-fuite + mesure du gain
13h00–14h30	Modèles avancés + 1ères erreurs	M5 : modèles alternatifs + tuning · M7 : démarre l'analyse d'erreurs sur modèle provisoire · M2 : prépare les visuels
14h30–15h15	Sélection finale	M5+M6 : choix du seuil, modèle final, submission.csv · M7 : enregistre la vidéo · M6 : finalise le README
15h15–15h45	Vérifications	Tous : relecture croisée README / notebook
15h45–16h00	Dépôt final	M1 : checklist finale + dernier commit

Points de synchronisation obligatoires : 10h30 (baseline prête) · 13h00 (features + 1er modèle avancé) · 14h30 (modèle final figé) · 15h45 (dernier commit).

Checklist avant le dernier commit (16h00)

- submission.csv : 2 000 lignes, 3 colonnes (reservation_id, probabilite_annulation, reservation_annulee), ordre initial des identifiants respecté
- Notebook exécutable de bout en bout depuis un noyau vierge
- Graines aléatoires fixées partout
- Aucune fuite du jeu de test dans les prétraitements
- README.md complété (toutes les sections, Q1 à Q9)
- Lien de la vidéo (3 à 5 minutes) accessible et vérifié
- requirements.txt à jour

Structure du projet (dépôt GitHub)

Structure recommandée pour que les 7 membres travaillent en parallèle sans conflits, tout en respectant les livrables exigés (notebook exécutable, submission.csv, README au canevas imposé).

```
atlantic-haven-hotels/
|
|-- data/
|   |-- raw/
|   |   |-- reservations_train.csv
|   |   |-- reservations_test.csv
|   |   |-- data_dictionary.csv
|   |-- processed/          # sorties intermediaires (features, splits)
|
|-- notebooks/
|   |-- 01_eda.ipynb          # Membre 2
|   |-- 02_baseline.ipynb    # Membre 3
|   |-- 03_validation.ipynb  # Membre 3
|   |-- 04_feature_engineering.ipynb # Membre 4
|   |-- 05_modeles_alternatifs.ipynb # Membre 5
|   |-- 06_interpretation_erreurs.ipynb # Membre 7
|   |-- notebook.ipynb      # notebook final fusionne - LE livrable
|
|-- src/
|   |-- __init__.py
|   |-- preprocessing.py     # pipeline partage (Membre 3)
|   |-- features.py          # feature engineering (Membre 4)
|   |-- validation.py        # split temporel, scoring (Membre 3)
|   |-- utils.py             # seed, chargement donnees, constantes
|
|-- models/
|   |-- modele_final.pkl     # (optionnel) modele serialise
|
|-- report/
|   |-- README.md            # rapport final (canevas complete)
|   |-- figures/             # graphiques exportes
|
|-- submission.csv           # livrable - a la racine
|-- requirements.txt
|-- .gitignore
|-- README.md
```

Pourquoi ce découpage

- notebooks/ avec un fichier par rôle : chacun travaille dans son propre notebook pour éviter les conflits Git constants (les .ipynb se mergent très mal en JSON). Le Membre 1 assemble le meilleur de chaque notebook dans notebook.ipynb aux points de synchro.
- src/ en modules Python réutilisables : le pipeline de prétraitement, la fonction de split temporel et le feature engineering sont codés une seule fois puis importés dans tous les notebooks — garantit que toute l'équipe utilise exactement le même prétraitement et la même validation.
- data/processed/ séparé de data/raw/ : raw/ n'est jamais modifié ; toute sortie intermédiaire va dans processed/.
- submission.csv à la racine : c'est le fichier le plus critique du jury, il ne doit pas être caché dans un sous-dossier.
- report/figures/ centralise les graphiques exportés pour que le README les référence avec des chemins relatifs stables.

À figer avant 08h30 et à communiquer à toute l'équipe : le Membre 1 doit créer le squelette vide (dossiers + fichiers src/ avec juste des « pass ») dès le début pour que chacun sache où pousser son travail dès la première heure.

.gitignore

```
__pycache__/  
*.pyc  
.ipynb_checkpoints/  
.venv/  
data/processed/*.csv  
models/*.pkl
```

requirements.txt

```
pandas  
numpy  
scikit-learn  
matplotlib  
seaborn  
xgboost  
lightgbm  
jupyter
```